Webscraping Básico

Benilton Carvalho & Guilherme Ludwig

Webscraping

- É possível "raspar" (*scrape*) informações de páginas da internet e guardálas em um banco de dados para análise posterior;
- Esta prática é chamada de webscraping;
- Utilizaremos os pacotes:
 - tidyverse: que disponibiliza o operador %>%;
 - rvest: que simplifica algumas operações dos pacotes xml2 e httr;
 - RSQLite: que permite o uso do SQLite dentro do R.

```
library(tidyverse)
library(rvest)
library(RSQLite)
```

Idéias

Uma página da web é um documento que pode ser exibido por um navegador. Estes documentos normalmente exibem resultados de consultas à bancos de dados, que são nosso principal interesse nesta disciplina. Em geral:

- Páginas simples podem ser acessadas através do R com o pacote rvest.
- Páginas dinâmicas que exijam autenticação do usuário, na forma de cookies, podem ser acessadas por meio do pacote httr.
- Nosso objetivo é coletar dados com o rvest e armazená-los em um banco de dados.

HTML

É preciso o conhecimento de HTML! Em geral, páginas HTML são texto estruturado, interpretado pelo navegador. Veja exemplos em: https://www.w3schools.com/html/html basic.asp

```
<!DOCTYPE html>
<html>
<body>
<h1>Um título</h1>
Um parágrafo
<img src="foto.jpg" alt="Uma foto legal">
<a href="http://www.uol.com.br">Link para o site do UOL</a>
</body>
</html>
```

Para o rvest, os itens <h1>, , e <a> são nós (em inglês, *node*). O nó tipo h1 é um cabeçalho, o p é parágrafo, enquanto o img é imagem e o a indica um link.

Ainda sobre HTML

Um nó table (rvest) define tabelas em HTML.

```
<!DOCTYPE html>
<html>
<body>
Curso
 Código
Estatística
 02
Matemática
 01
</body>
</html>
```

Ainda sobre HTML

Um nó li (rvest) define listas em HTML.

```
<!DOCTYPE html>
<html>
<body>

    Café
    Chá
    Leite

</body>
</body>
</html>
```

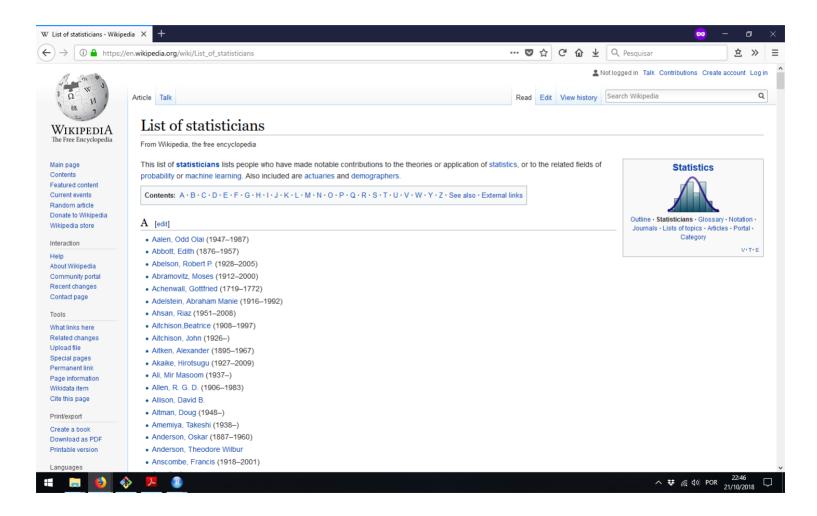
Exemplo: wikipedia

A *wikipedia* é particularmente interessante para scraping, pois ela possui muitas páginas com listas, de onde podemos começar nossas buscas. Por exemplo,

https://en.wikipedia.org/wiki/List_of_statisticians

Podemos estar interessados em compilar uma lista com nome, *alma mater*, data de nascimento (e local), e data de falecimento (caso já tenha falecido) de estatísticos famosos.

Lista de Estatísticos



Página: George Box

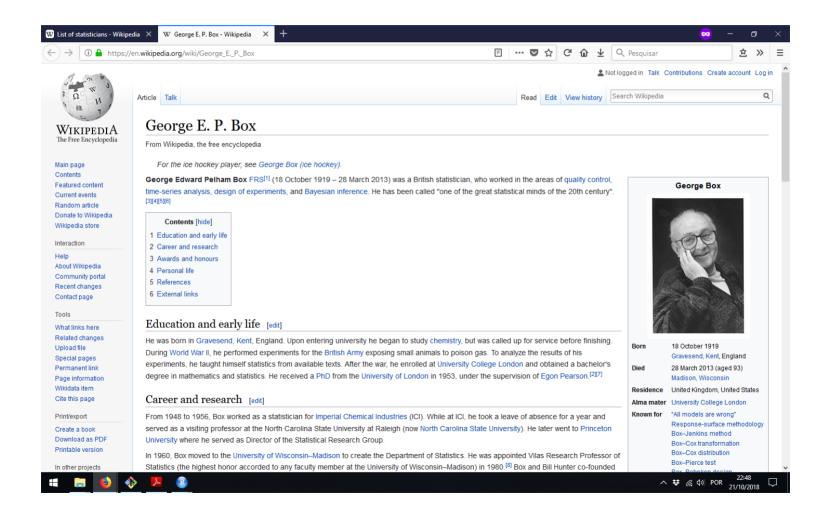
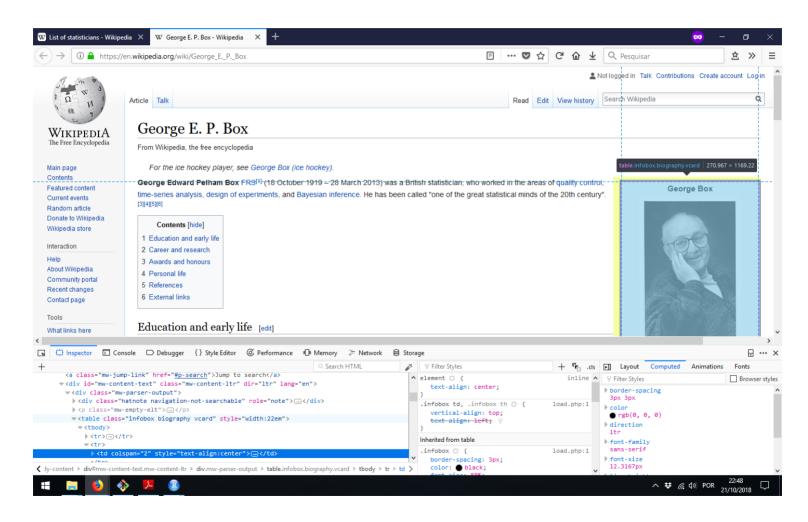


Tabela de Interesse



SelectorGadget

Uma ferramenta recomendada pelo rvest é o chamado SelectorGadget (https://selectorgadget.com/), que mostra o nome de um "selector" em CSS. Há uma extensão para o navegador Chrome que permite que você use o SelectorGadget em qualquer página.

Com o selector correto, você pode acessá-lo usando html_nodes(). Selectors interessantes incluem "table.<nome>" e "li". É preciso inspecionar as páginas de interesse caso a caso.

Usando SelectorGadget (Chrome)

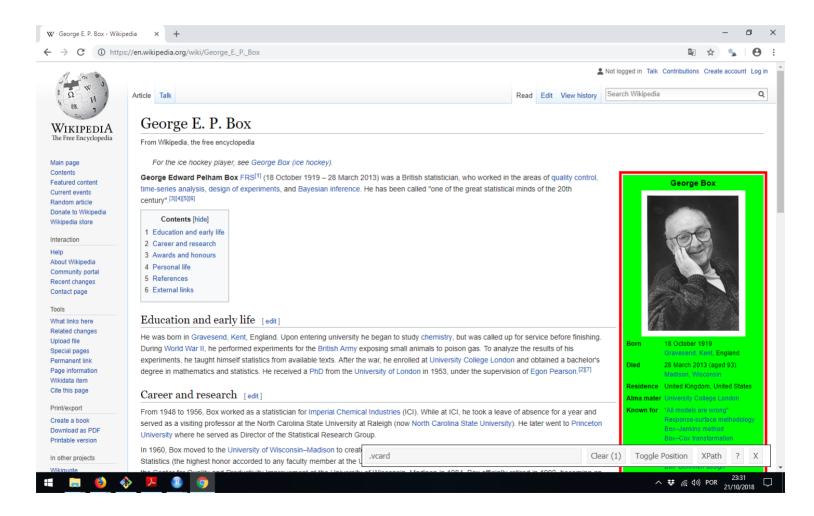


Tabela de interesse

```
url = "https://en.wikipedia.org/wiki/George_E._P._Box"
webpage <- read_html(url)

table <- webpage %>%
  html_node(".vcard") %>%
  html_table(header = FALSE) %>%
  as_tibble()
```

```
## # A tibble: 17 x 2
##
                     X2
     Х1
## <chr>
                     <chr>
##
   1 George Box
                     George Box
   2 ""
##
                     (1919-10-18)18 October 1919Gravesend, Kent, England
##
   3 Born
##
   4 Died
                     28 March 2013(2013-03-28) (aged 93)Madison, Wiscor
   5 Residence
                     United Kingdom, United States
##
   6 Alma mater
                          University College London
##
   7 Known for
                          ""All models are wrong"\nResponse-surface methodol
##
                     "Shewhart Medal (1968)\nWilks Memorial Award (1972)\nR.
## 8 Awards
   9 Scientific car... Scientific career
##
                                                                    13 / 27
```

Conteúdo (limpeza com regex)

table %>% mutate(X1 = str_replace_all(X1, "\\s", " "),

14 Doctoral stude... John F. MacGregor Greta M. Ljung

```
X2 = str_replace_all(X2, "\\s", " "),
                  X2 = str_replace_all(X2, "\\[[[:digit:]]\\]", " "),
                  X2 = str_replace_all(X2, " ", " "))
## # A tibble: 17 x 2
##
     X1
                      X2
##
   <chr>
                      <chr>
##
   1 George Box
                      George Box
## 2 ""
                      11 11
## 3 Born
                      (1919-10-18)18 October 1919Gravesend, Kent, England
## 4 Died
                      28 March 2013(2013-03-28) (aged 93) Madison, Wisconsin
## 5 Residence
                      United Kingdom, United States
## 6 Alma mater
                      University College London
## 7 Known for
                      "All models are wrong" Response-surface methodology EVO
## 8 Awards
                      Shewhart Medal (1968) Wilks Memorial Award (1972) R. A.
## 9 Scientific car... Scientific career
## 10 Fields
                      Statistics Design of experiments Bayesian statistics Ti
## 11 Institutions
                      ICI Princeton University University of Wisconsin-Madiso
                      Departures from Independence and Homoskedasticity in th
## 12 Thesis
## 13 Doctoral advis... "Egon Pearson H. O. Hartley "
```

14 / 27

Procurando Links

Inspecionando a página no navegador, é possível observar que, dentro de body #content (o conteúdo da página), os links estão guardados no node "li".

```
url = "https://en.wikipedia.org/wiki/List_of_statisticians"
listPages <- read_html(url)
links <- listPages %>%
  html_nodes("li")
```

Procurando Links

links

```
## {xml nodeset (742)}
          [1] <a href="/wiki/Outline of statistics" title="Outline of st
##
          [2] <a class="mw-selflink selflink">Statisticians</a>
##
          [3] <a href="/wiki/Glossary_of_probability_and_statistics" title="Glo
##
          [4] <a href="/wiki/Notation_in_probability_and_statistics" title="Not
##
##
          [5] <a href="/wiki/List_of_statistics_journals" title="List of statis"
          [6] <a href="/wiki/Lists_of_statistics_topics" title="Lists of statis"
##
          [7] <a href="/wiki/List_of_statistics_articles" title="List of statis"
##
          [8] \n<a href="/wiki/File:Nuvola_apps_edu_mathematics_blue-p.svg" cla
##
          [9] <a href="/wiki/Category:Statistics" title="Category:Statistics">C
##
       [10] <a href="/wiki/Template:Statistics_topics_sidebar
## [11] <a href="/wiki/Template_talk:Statistics_topics_si
## [12] <a class="external text" href="https://en.wikiped
## [13] <a href="#A">A</a>
## [14] <a href="#B">B</a>
## [15] <a href="#C">C</a>
## [16] <a href="#D">D</a>
## [17] <a href="#E">E</a>
## [18] <a href="#F">F</a>
## [19] <a href="#G">G</a>
                                                                                                                                                                                 16 / 27
```

"Sajid Ali Khan, Rawalakot" até "Zipf, George Kingsley"

```
estat1 = links %>%
  as.character %>%
  grep("Sajid Ali Khan, Rawalakot", .)
estatN = links %>%
  as.character %>%
  grep("Zipf, George Kingsley", .)
estat1
## [1] 40
estatN
## [1] 679
links <- links[estat1:estatN]</pre>
```

Páginas individuais

O objeto links possui os endereços no formato XML e não se restringem apenas aos endereços.

```
links
```

```
## {xml nodeset (640)}
          [1] \n<a href="/w/index.php?title=Sajid_Ali_Khan&amp;action=edit&amp;
##
##
          [2] \n<a href="/wiki/Odd_Aalen" title="Odd Aalen">Aalen, Odd Olai</a>
          [3] \n<a href="/wiki/Edith_Abbott" title="Edith Abbott">Abbott, Edith
##
          [4] \n<a href="/wiki/Robert P. Abelson" class="mw-redirect" title="Ro
##
          [5] \n<a href="/wiki/Moses_Abramovitz" title="Moses Abramovitz">Abramovitz">Abramovitz"
##
          [6] \n<a href="/wiki/Gottfried Achenwall" title="Gottfried Achenwall"
##
##
          [7] \n<a href="/wiki/Abraham_Manie_Adelstein" title="Abraham Manie Adelstein" title="Adelstein" title="Abraham Manie Adelstein" title="Adelstein" title="Adelste
          [8] \n<a href="/wiki/Riaz Ahsan" title="Riaz Ahsan">Ahsan, Riaz</a> (
##
          [9] \n<a href="/wiki/Beatrice_Aitchison" title="Beatrice Aitchison">A
##
       [10] \n<a href="/wiki/John Aitchison" title="John Aitchison">Aitchison
## [11] \n<a href="/wiki/Alexander_Aitken" title="Alexander Aitken">Aitken
## [12] \n<a href="/wiki/Hirotsugu_Akaike" class="mw-redirect" title="Hir
## [13] \n<a href="/wiki/Mir_Masoom_Ali" title="Mir Masoom Ali">Ali, Mir
## [14] \n<a href="/wiki/R._G._D._Allen" title="R. G. D. Allen">Allen, R.
## [15] <a href="/wiki/David_B._Allison" title="David B. Allison">Allison
## [16] \n<a href="/wiki/Doug_Altman" title="Doug Altman">Altman, 180/ug</a/>//a
```

Páginas individuais

Devemos lembrar que os endereços nos links são armazenados no nó <a>.

```
links %>%
  html nodes("a")
## {xml nodeset (640)}
    [1] <a href="/w/index.php?title=Sajid Ali Khan&amp;action=edit&amp;redlir
    [2] <a href="/wiki/Odd Aalen" title="Odd Aalen">Aalen, Odd Olai</a>
##
    [3] <a href="/wiki/Edith_Abbott" title="Edith Abbott">Abbott">Abbott, Edith</a>
##
    [4] <a href="/wiki/Robert_P._Abelson" class="mw-redirect" title="Robert F
##
    [5] <a href="/wiki/Moses_Abramovitz" title="Moses Abramovitz">Abramovitz,
##
    [6] <a href="/wiki/Gottfried_Achenwall" title="Gottfried Achenwall">Achen
##
    [7] <a href="/wiki/Abraham_Manie_Adelstein" title="Abraham Manie Adelstei
##
    [8] <a href="/wiki/Riaz Ahsan" title="Riaz Ahsan">Ahsan, Riaz</a>
##
##
    [9] <a href="/wiki/Beatrice_Aitchison" title="Beatrice Aitchison">Aitchis
## [10] <a href="/wiki/John_Aitchison" title="John Aitchison">Aitchison, John
## [11] <a href="/wiki/Alexander_Aitken" title="Alexander Aitken">Aitken, Ale
## [12] <a href="/wiki/Hirotsugu_Akaike" class="mw-redirect" title="Hirotsugu
## [13] <a href="/wiki/Mir_Masoom_Ali" title="Mir Masoom Ali">Ali, Mir Masoom
## [14] <a href="/wiki/R._G._D._Allen" title="R. G. D. Allen">Allen, R. G. D.
## [15] <a href="/wiki/David_B._Allison" title="David B. Allison">Allison, Da
## [16] <a href="/wiki/Doug_Altman" title="Doug Altman">Altman, Doug<1a>/ 27
```

Páginas Individuais

No slide anterior, você deve observar que, dentro do nó <a>, existe um atributo href, que possui o link relativo (dentro da página da Wikipedia) para cada uma das páginas.

```
links %>%
  html nodes("a") %>%
  html_attr("href") # Salvar title também!
     [1] "/w/index.php?title=Sajid_Ali_Khan&action=edit&redlink=1"
##
    [2] "/wiki/Odd Aalen"
##
    [3] "/wiki/Edith_Abbott"
##
    [4] "/wiki/Robert P. Abelson"
##
##
    [5] "/wiki/Moses Abramovitz"
    [6] "/wiki/Gottfried_Achenwall"
##
    [7] "/wiki/Abraham Manie Adelstein"
##
    [8] "/wiki/Riaz_Ahsan"
##
##
     [9] "/wiki/Beatrice Aitchison"
    [10] "/wiki/John_Aitchison"
##
    [11] "/wiki/Alexander_Aitken"
##
    [12] "/wiki/Hirotsugu_Akaike"
##
    [13] "/wiki/Mir_Masoom_Ali"
##
##
    [14] "/wiki/R. G. D. Allen"
```

Criando os links completos

Como visto anteriormente, o atributo href refere-se ao endereço **relativo** ao endereço padrão da Wikipedia. Para montar o endereço completo, é preciso adicionar a expressão https://en.wikipedia.org antes do endereço relativo.

```
li <- links %>% html nodes("a") %>% html attr("href")
li <- paste0("https://en.wikipedia.org", li)</pre>
li %>% head()
## [1] "https://en.wikipedia.org/w/index.php?title=Sajid_Ali_Khan&action=edit
## [2] "https://en.wikipedia.org/wiki/Odd_Aalen"
## [3] "https://en.wikipedia.org/wiki/Edith_Abbott"
## [4] "https://en.wikipedia.org/wiki/Robert_P._Abelson"
## [5] "https://en.wikipedia.org/wiki/Moses_Abramovitz"
## [6] "https://en.wikipedia.org/wiki/Gottfried_Achenwall"
names <- links %>% html_nodes("a") %>% html attr("title")
names %>% head()
## [1] "Sajid Ali Khan (page does not exist)"
## [2] "Odd Aalen"
```

Curadoria Manual

```
bad = c("page does not exist", "Florence Nightingale",
         "Harold Wilson", "Robert P. Abelson")
bad1 = unlist(sapply(bad, grep, names))
bad2 = unlist(sapply(c("mshkhan", "redlink", "orghttp"), grep, li))
 (remove = c(bad1, bad2))
    page does not exist1 page does not exist2 Florence Nightingale1
##
##
                                            382
                                                                   131
## Florence Nightingale2
                                  Harold Wilson
                                                    Robert P. Abelson
##
                     428
                                            617
                                                                     4
                                       redlink1
                                                              redlink2
##
                 mshkhan
##
                     469
                                                                   382
                orghttp1
                                       orghttp2
##
##
                     469
                                            567
rm(bad, bad1, bad2)
```

Curadoria Manual

```
names = names[-remove]
li = li[-remove]
pessoas = tibble(nome=names, link=li)
pessoas %>% head()
## # A tibble: 6 x 2
                              link
##
     nome
##
     <chr>
                              <chr>>
## 1 Odd Aalen
                              https://en.wikipedia.org/wiki/Odd_Aalen
                              https://en.wikipedia.org/wiki/Edith_Abbott
## 2 Edith Abbott
                              https://en.wikipedia.org/wiki/Moses_Abramovitz
## 3 Moses Abramovitz
                              https://en.wikipedia.org/wiki/Gottfried_Achenwal
## 4 Gottfried Achenwall
## 5 Abraham Manie Adelstein https://en.wikipedia.org/wiki/Abraham_Manie_Adel
## 6 Riaz Ahsan
                              https://en.wikipedia.org/wiki/Riaz_Ahsan
```

Função para Extração de Tabela

```
f <- function(x){</pre>
 ifelse(length(x) == 0, NA_character_, x)
extraiTabela = function(mylink){
 table <- read_html(mylink) %>% html_node(".vcard")
 if (is.na(html name(table))) return(NULL)
 if (html name(table) != "table") return(NULL)
 table = table %>% html table(header = FALSE) %>%
          mutate(X1 = str_replace_all(X1, "\\s", " "),
                 X2 = str replace all(X2, "\s", " "),
                 X2 = str_replace_all(X2, "\\[[[:digit:]]\\]", " "),
                 X2 = str replace all(X2, " ", " "))
 tibble(link = mylink,
        Born = f(table[grep("Born", table$X1), 2]),
        Died = f(table[grep("Died", table$X1), 2]),
        AlmaMater = f(table[grep("Alma", table$X1), 2]))
```

Extraindo tabelas (demora alguns minutos...)

```
library(doMC) ## se windows library(doParallel)
registerDoMC(4) ## se windows registerDoParallel(nproc)
out = foreach(thislink=li, .combine=rbind) %dopar% {
   extraiTabela(thislink)
}
final = pessoas %>% inner_join(out, by='link')
final[, 1:3] %>% head
```

```
## # A tibble: 6 x 3
##
                    link
                                                     Born
     nome
                    <chr>
                                                     <chr>>
##
     <chr>
## 1 Odd Aalen
                    https://en.wikipedia.org/wiki... (1947-05-06) May 6, 1947 (
## 2 Edith Abbott https://en.wikipedia.org/wiki... (1876-09-26) September 26,
## 3 Moses Abramov... https://en.wikipedia.org/wiki... (1912-01-01)January 1, 191
## 4 Gottfried Ach... https://en.wikipedia.org/wiki... (1719-10-20)20 October 171
                    https://en.wikipedia.org/wiki... 1951, December 25Karachi,
## 5 Riaz Ahsan
## 6 Beatrice Aitc... https://en.wikipedia.org/wiki... (1908-07-18)18 July 1908Po
```


5 November 8, 2008(2008-11-08) (ag... University of KarachiAdamjee Governmer ## 6 22 September 1997(1997-09-22) (a... Goucher College (BA)Johns Hopkins Univ

4 1 May 1772(1772-05-01) (aged 52)... <NA>

Obrigado!